

Datenstruktur B A U M

Die Datenstruktur Liste ist dynamisch und sehr flexibel. Unpraktisch wird sie allerdings, wenn ein Element innerhalb der Liste gesucht wird. Werden mehrere Millionen Datensätze in einer sortierten Liste verwaltet, liegt der „Worst case“ vor, wenn gerade das letzte Element in der Liste vom Benutzer gesucht wird. Dann muss die ganze Liste durchlaufen werden, d.h. jedes Element ausgelesen werden, um das gesuchte Element zu finden. Bei einem Baum darf jeder Knoten beliebig viele Nachfolger besitzen. Beispiel: Dateisystem




Die Datenstruktur **B a u m** bietet eine schnellere Lösung!

Datenstruktur B I N Ä R B A U M

Begriffsdefinition

Ein **Binärbaum** ist grundlegend genauso aufgebaut wie eine (einfach) verkettete Liste, nur dass jeder Knoten bis zu zwei Nachfolger haben kann. Deshalb spricht man auch von einem linken und einem rechten Nachfolger. Ein Knoten kann also effektiv keine, nur einen linken, nur einen rechten oder zwei Nachfolger haben.



Man kann einen beliebigen Knoten und dessen Nachfolger (und deren Nachfolger ...) aus einem Binärbaum herausnehmen und hat wieder einen Binärbaum vor sich. Auch beim Binärbaum hat also ein beliebiger Teil des Ganzen wieder exakt dieselbe Struktur wie das Ganze selbst. Deshalb implementieren wir den Binärbaum nach dem **Composite-Pattern**.

- Den ersten Knoten – den, der keine Vorgänger hat – nennt man **Wurzel (root)**.
- Knoten, die wenigstens einen Nachfolger haben, nennt man **innere Knoten**.
- Knoten, die keine Nachfolger mehr haben, nennt man **Blatt**.
- Die Verbindungslinien zu den Nachfolgeknoten nennt man **Kante**.
- Sucht man sich einen Weg von der Wurzel zu einem bestimmten Knoten, so spricht man von einem **Pfad**.

Ein Pfad beginnt immer bei der Wurzel (w) und geht dann mit links (l) oder rechts (r) weiter bis zu einem bestimmten Knoten.

Beispiel: Der Pfad zum Knoten ganz links unten in obigem Bild lautet: w l l l.

- Die Anzahl der Knoten im längsten möglichen Pfad nennt man **Tiefe (Höhe) des Baums**.

(**Achtung:** Pfade gehen maximal bis zu einem Blatt, nie bis zu einem Abschluss!)

- In der Zeichnung nebeneinander liegende Knoten nennt man eine **Ebene**. Die Ebene der Wurzel nennt man **Ebene 1**, die Ebene der Nachfolger der Wurzel ist **Ebene 2**, usw.

Aufgabe 1:

- a) Welche Tiefe hat der Baum in obigem Bild?
- b) Wie viele Knoten befinden sich bei obigem Baum in Ebene 4?
- c) Wie viele Knoten passen maximal in die Ebene 1, 2, 3, 4, ... ? Stelle eine allgemeine Formel in Abhängigkeit der Tiefe auf.
- d) Wie viele Knoten passen insgesamt maximal in einen Binärbaum der Tiefe 1, 2, 3, 4, ... ? Stelle eine allgemeine Formel in Abhängigkeit der Tiefe auf.
- e) Gib den Pfad zum rechten Knoten der untersten Ebene in obigem Bild an.
- f) **Zeichne ein Klassendiagramm eines Binärbaums nach Composite-Pattern.**
- g)
 - Implementiere dieses Klassendiagramm in JAVA.
 - Erstelle hierzu alle nötigen Klassen und Referenzattribute.
 - Die Konstruktoren sollen die Referenzattribute bereits initialisieren.
 - Darüber hinaus kannst du bereits alle Setter- und Getter-Methoden implementieren.
 - Das Interface soll wie bei der Liste eine Methode `info()`: String sowie Vergleichsmethoden vorschreiben.

Einsatzbereich eines Binärbaums

Betrachten wir zunächst noch einmal kurz die Datenstruktur LISTE und darin unsere bisher implementierte Methoden *sortiertEinfuegen(...)* und *suchen(...)*. Beide haben bisher gute Dienste geleistet. Wie verhalten sich diese Methoden aber, wenn wir sehr viele Datensätze verwalten. Nehmen wir z.B. die Datenverwaltung von *Facebook* oder *WhatsApp*. Hier werden etwa ein Milliarde (1.000.000.000) Datensätze verwaltet.

Aufgabe 2:


Stelle dir die beiden Extremfälle einer Suche nach einem Nutzer mit der Kennung **aaaaaaaaaa** im Vergleich zur Suche nach dem Nutzer mit der Kennung **zzzzzzzzzz** vor.

- a) Was geschieht jeweils innerhalb der Liste, bis der Nutzer gefunden wird.
- b) Nehmen wir an, ein Vergleich auf dem Server dauert $5\mu s$ und ein Referenz-Wechsel auf den Nachfolger $1\mu s$.
Wie lange dauert dann vermutlich das Finden von **aaaaaaaaaa**?
Wie lange dauert dann vermutlich das Finden von **zzzzzzzzzz**?
Wie lange dauert dann im Mittel eine Suche?
- c) Wie könnte man anders vorgehen, sodass die Suche in der Liste im Mittel erheblich schneller stattfinden kann?
Beschreibe kurz deinen Algorithmus.

Ein mögliches Verfahren zur schnelleren Suche in einer Liste könnte folgendermaßen vorgehen:

- Nimm das mittlere Glied der sortierten Liste. Bei geradzahlgiger Länge der Liste nimm z.B. den linken der beiden mittleren Knoten.
- Vergleiche den Such-String mit der Info dieses Knotens. War die Suche erfolgreich, so gib *true* zurück. Ist der Such-String jedoch „größer als“ die Info, so verfähre auf dieselbe Art mit der rechten Teilliste. War der Such-String „kleiner als“ die Info, so mache mit der linken Teilliste entsprechend weiter.
- Besteht eine Teilliste nur noch aus einem Element und entspricht dessen Info nicht dem Such-String oder hat eine Teil-Liste die Länge 0, so gib *false* zurück.

In einem (balancierten) Binär-Baum werden die Knoten nun genau in der Reihenfolge erzeugt, wie man bei der Suche in einer sortierten Liste vorgehen würde. Das folgende Beispiel soll das veranschaulichen:



Eine **Ordnung in einem Binärbaum** wird also dadurch realisiert, dass ausgehend von einem beliebigen Knoten

- alle Elemente im **linken Teilbaum** „**kleiner als**“ das Element im darüber liegenden Knoten sind.
- alle Elemente im **rechten Teilbaum** „**größer als**“ das Element im darüber liegenden Knoten sind.

Hierbei wird vereinfachend davon ausgegangen, dass wir nach einem eindeutigen Schlüssel (ähnlich dem Primärschlüssel bei einer Datenbanktabelle) sortieren, dass es also keine doppelten Elemente gibt. Das Einfügen eines „doppelten Datensatzes“ sollte also zu einer Fehlermeldung führen!

Anzahl an Vergleichen bei Suchoperationen (Binärbaum vs. Liste)

Beispiel:

In einem Binär-Baum werden 10 000 Elemente gespeichert. Welche Ober- bzw. Untergrenze für die Anzahl der maximal nötigen Vergleiche, die zum Suchen eines Elements nötig sind, ergeben sich?

- a) „Worst-Case“: **der Baum ist zu einer Liste entartet.**

→ Es benötigt im Maximalfall 10 000 Vergleiche das Element zu Suchen.

- b) „Best-Case“: **der Baum ist optimal**, d.h. alle Ebenen (bis auf die unterste) sind voll ausgefüllt.

→ Im schlimmsten Fall muss ein Pfad von der Wurzel bis zum Blatt durchlaufen werden. D.h. die Tiefe entspricht der Anzahl an nötigen Vergleichen.

Wir wissen:

$2^h - 1 = n$, wobei h = Höhe (Tiefe) und n = Anzahl an enthaltenen Knoten.

Daraus ergibt sich:

$$2^h - 1 = 10\,000 \quad | + 1$$

$$2^h = 10\,001 \quad | \log_2(\dots)$$

$$h = \log_2(10\,001) \approx 13,29$$

→ es sind im Maximalfall bei einem optimalen Baum 14 Vergleiche nötig.

Aufgabe 3:

- a) Zeichne einen Binärbaum, in den die Buchstaben M, D, X in genau dieser Reihenfolge eingefügt wurden.
- b) Wo käme beim Baum aus Aufgabe a) der Buchstabe P hin, wenn er nachträglich eingefügt werden soll?
Zeichne ein Sequenzdiagramm, welches alle nötigen Schritte veranschaulicht, die nötig sind, um P einzufügen.

- c) **Implementiere die Methode** `einguegen(T t) : void` im `BinärBaum`.

Ein Knoten prüft erst, ob er das Problem an den linken oder rechten Nachfolger delegieren muss und setzt seinen entsprechenden Nachfolger dann neu auf die Antwort dieses Nachfolgers.

Aufgabe 4:

- a) Formuliere eine Strategie, wie man in einem Binärbaum suchen kann, ob sich schon ein Element mit einem bestimmten Info-String darin befindet.
Betrachte den Binärbaum aus Aufgabe 3a) und zeichne ein Sequenzdiagramm, welches die Suche nach „F“ beschreibt.

- b) **Implementiere die Methode** `istEnthalten(String s): boolean`.

Das Vorgehen ähnelt dem des Einfügens:

Der `BinBaum` delegiert das Problem an seine Wurzel weiter.

Ein Knoten gibt `true` zurück, wenn er ein Element mit dem gesuchten Info-String enthält. Ansonsten delegiert er die Suche an seinen linken bzw. rechten Nachfolger, je nachdem ob der Such-String kleiner oder größer als der eigene Info-String ist. Da `String` kein primitiver Datentyp ist, funktionieren Vergleiche auf Strings mit der Methode `String.compareTo(String s)`. Siehe Java-API-Doc.

Ein Abschluss gibt immer `false` zurück.

- c) **Ändere die Signatur deiner Einfügemethode zu `einguegen(T t): boolean` um, sodass zuerst geprüft wird, ob sich das einzufügende Element nicht schon im Binärbaum befindet. Ist das der Fall, so gib `false` zurück, andernfalls füge das Element ein und gib `true` zurück.**

Aufgabe 5:

- a) Formuliere eine Strategie, wie man bei einem Binärbaum die (maximale) Tiefe herausfinden kann.
Zeichne einen Binärbaum, in den der Reihe nach „M“, „F“, „R“ und „V“ eingefügt werden und teste händisch deinen Algorithmus, ob er das Gewünschte leistet.

- b) **Implementiere nun die Methode `tiefe(): int`.**


Der `BinBaum` delegiert die Methode an seine Wurzel weiter.

Ein Knoten fragt erst seinen linken und rechten Nachfolgebäum nach dessen Tiefe. Zum größeren der beiden Werte (Java-API-Doc `Math.max(zahl1, zahl2, ...)`) addiert er Eins (der Knoten selbst steht ja noch über den beiden Nachfolgebäumen) und gibt diesen Wert zurück.

Ein Abschluss gibt generell 0 zurück.

Traversierung eines Binärbaums

Um z.B. alle Elemente eines Binärbaums zu zählen braucht man einen Algorithmus, der sicher über alle Knoten läuft und dabei keinen auslässt oder mehrfach zählt. Sprich: Unter dem Begriff **Traversierung** versteht man, dass ein Baum derartig durchlaufen wird, so dass **jeder Knoten** dabei **genau einmal** erreicht wird. Es gibt verschiedene Arten, dies zu tun:



1. **in-order-Durchlauf**

durchlaufe den linken Teilbaum, dann den Knoten selbst und anschließend den rechten Teil-Baum => (in-order: in der Reihenfolge von links nach rechts)

Vorteil des Verfahrens: Der Binärbaum wird sortiert ausgegeben.

Allerdings ist dieses Verfahren nicht zum Abspeichern geeignet, da beim Einlesen in dieser Form ein entarteter Baum in Form einer Liste entstehen würde.

Am Beispielbaum angewendet ergibt dies folgende Ausgabe: A, B, C, D, E, F, G

2. **prä-order-durchlauf**

durchlaufe zuerst den Knoten selbst, dann den linken Teilbaum und anschließend den rechten Teilbaum

(prä-order: der Knoten selbst kommt **vor** dem linken und rechten Teilbaum)

Dieses Verfahren eignet sich besonders zum Abspeichern von Binärbäumen, denn wenn man die Elemente wieder einliest, erhält man den gleichen Baum.

Am Beispielbaum angewendet ergibt dies folgende Ausgabe: D, B, A, C, F, E, G

3. **post-order-Durchlauf**

durchlaufe den linken Teilbaum, dann den rechten Teil-Baum und anschließend den Knoten selbst

(post-order: der Knoten selbst kommt erst **nach** dem linken und rechten Teilbaum)

Dieses Verfahren wird in der Praxis eher weniger gebraucht, wird aber zur Vollständigkeit mit aufgeführt.



Am Beispielbaum angewendet ergibt dies folgende Ausgabe: A, C, B, E, G, F, D

Dabei wird der **Algorithmus** jeweils **rekursiv** auf den linken bzw. rechten Teilbaum angewendet.

Beim Composite-Pattern wird die **Abbruchbedingung** wieder in der Klasse **Abschluss** realisiert.

Aufgabe 6:

- a) Betrachte die beiden untenstehenden Bäume.
Gib seine Elemente händisch einmal in-order, einmal prä-order und einmal post-order aus.



- b) **Implementiere nun die Methoden**
`inOrder(): void` , `praeOrder(): void` ,
`postOrder(): void` **indem du den Info-String jedes Elements auf der Konsole mit `System.out.println(...)` ausgeben lässt.**


c) **Implementiere zusätzlich eine Methode `anzahlElemente(): int`, um die Anzahl an Elementen des Baums zu bestimmen.**

Löschen aus einem Binärbaum

Sollen Elemente wieder aus einem Binärbaum gelöscht werden, so unterscheidet man drei Fälle:


1. Fall: Blattknoten

Der zu löschende Knoten ist ein Blatt und besitzt **keinen Nachfolger**. Somit kann der Knoten ohne Weiteres aus dem Baum gelöscht werden. Die Referenz wird auf einen Abschluss gesetzt.



2. Fall: Innerer Knoten mit nur einem Nachfolger



In diesem Fall wird die Referenz auf den zu löschenden Knoten einfach durch dessen Nachfolger ersetzt.



3. Fall: Innerer Knoten mit zwei Nachfolgern

Nun kann der Knoten nicht einfach gelöscht werden! Es gibt nur eine Referenz auf den zu löschenden Knoten, dieser hinterlässt nach dem Löschen aber zwei Referenzen auf seine Nachfolger. Was nun?


Kurzfassung: In diesem Fall wird der Knoten, der in der Inorder-Traversierung unmittelbar auf den zu löschenden Knoten folgt (sprich der nächstgrößere Knoten), an dessen Stelle gesetzt. Hierbei ergibt sich wieder einer der Fälle 1 – 2.



Versuche zunächst, die Richtigkeit dieses Algorithmus (ohne zu programmieren) an einigen Beispielen zu überprüfen:

Aufgabe 7:

Betrachte den folgenden Binärbaum:



- a) Teste den **Fall 1** an den Knoten mit dem Inhalt 3 und 7.
- b) Teste den **Fall 2** an den Knoten mit dem Inhalt 6, 10 und 16.
- c) Teste den **Fall 3** am Knoten mit dem Inhalt 5. Wähle das Nächstkleinere.
- d) Teste den **Fall 3** an den Knoten mit dem Inhalt 5. Wähle das Nächstgrößere.
- e) Teste den **Fall 3** am Knoten mit dem Inhalt 15.
Wähle einmal das Nächstkleinere und einmal das Nächstgrößere.

Programmiertechnische Umsetzung von Fall 3:

Die Lösung besteht darin, den Knoten mit dem nächstgrößeren (kleineren) Inhalt zu suchen und diesen Inhalt zurückzugeben. Man findet diesen Inhalt nach folgendem Algorithmus:

- **nächstgrößeres Element**
Gehe zum rechten Nachfolger und von dort aus so lange rekursiv nach links, wie es einen linken Nachfolger gibt. Übergebe jeweils die Daten (die Auflistbarreferenz) des aktuellen Knoten und der der Abschluss gibt den letzten Inhalt zurück.
- **nächstkleineres Element**
Gehe zum linken Nachfolger und von dort aus so lange nach rechts, wie es einen rechten Nachfolger gibt. Übergebe jeweils die Daten des aktuellen Knoten und der der Abschluss gibt den letzten Inhalt zurück.

Anschließend kopiert man den Inhalt dieses Knotens in den eigentlich zu löschenden Knoten und löscht stattdessen den Knoten mit dem nächstgrößeren (kleineren) Inhalt. Dieser ist löschtbar, da für diesen Knoten mit dem nächstgrößeren (kleineren) Inhalt der Fall 1 oder 2 gilt.

Aufgabe 8:

Implementiere die Methode `entferne(String s)` : `boolean`.

Tipps:

- 1) Es ist sinnvoll, in den Klassen `Element/Knoten/Abschluss` zwei Methoden **`naechstGroesseres(T t): T`** und **`naechstKleineres(T t): T`** einzuführen, mit denen man eine Referenz auf den Inhalt des Knotens mit dem nächstgrößeren (kleineren) Element erhält.
- 2) Teste diese Methoden durch Erzeugung eines Baums in BlueJ. Zeichne zunächst einen Testbaum auf dem Papier. Erstelle gemäß der Vorlage auf Papier den Binärbaum in BlueJ. „Hole“ (funktioniert nur wenn die Attribute – `root` und die Nachfolger – `public` sind) dir einen Knoten im Baum: Rufe wie in der obigen Anleitung beschrieben auf seinem rechten Nachbarn die Methode `naechstGroesseres(null)` auf bzw. auf seinem linken Nachbarn die Methode `naechstKleineres(null)` und es sollte das jeweilig passende größere/kleinere Element im Baum ausgegeben werden.
- 3) Die Methode **`entferne(String s)`** in der **Klasse `BINBAUM`** gibt einen **`boolean`** zurück:
true, wenn das Element im Baum gefunden und gelöscht wurde;
false, wenn es im Baum kein solches Element gibt;
Der Baum setzt seine Wurzel neu auf die Antwort der Wurzel, wenn er sie mit der Löschung beauftragt.
- 4) In der **Klasse `KNOTEN`** gibt die Methode **`entferne(String s)`** das **`Element`** zurück, welches das aufrufende Objekt als seinen linken bzw. rechten Nachfolger (oder der Baum als Wurzel) setzen soll (Composite-Pattern).
Es wird zuerst überprüft, ob der Knoten selbst gelöscht werden soll.
Wenn JA, dann arbeitet man die Fälle „kein Nf“, „nur liNf“, „nur reNf“, „2 Nf“ ab.
Bei zwei Nachfolgern gibt man das Problem an einen Nachfolgebäum weiter, nachdem der neue Datensatz in diesen Knoten kopiert wurde.
Wenn NEIN, dann setzt man abhängig vom Entferne-String den linken oder rechten Nf auf das, was dieser antwortet, wenn er den Löschauftrag bekommt (Composite-Pattern) und gibt sich selbst zurück.
- 5) **Wann nimmt man das nächst größte oder kleinste Element?**
Man könnte sich stets so entscheiden, dass der Löschauftrag an den tieferen der beiden Nachfolgebäume weiter gereicht wird.
(Somit gleicht der Baum unterschiedliche Tiefen der Nachfolgebäume beim Löschen zumindest ein wenig aus.)

Nicht mehr Teil des Schulstoffs: Balancierte Bäume (AVL-Bäume)